

本科生毕业论文

题目：PLIF 在脉冲强化学习中的任务相关优势分析

学 院：
专 业：
年 级：
姓 名：
学 号：
指导教师：

独创性声明

本人声明：所呈交的毕业设计（论文），是在指导教师指导下独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本毕业设计（论文）中不包含任何他人已经发表或撰写过的研究成果。对本文研究工作做出贡献的个人和集体，均已在文中以明确方式标明。

论文作者签名：

年 月 日

本人声明：本毕业设计（论文）是本人指导学生完成的研究成果，已经审阅过论文的全部内容。

论文指导教师签名：

年 月 日

摘 要

脉冲神经网络具有事件驱动计算、时序信息处理和低功耗部署潜力，但其离散脉冲发放机制也给连续控制强化学习带来了梯度传播和动作表达方面的困难。本文围绕可学习膜时间常数的 PLIF 神经元是否能够提升脉冲 Actor 在连续控制任务中的学习性能展开研究。在 Proxy Target 与 TD3 框架下，本文以固定膜电位衰减系数的 LIF 神经元为主要对照，分析 PLIF 在不同 MuJoCo 任务中的性能差异及其可能机制。现有实验结果表明，PLIF 在 Walker2d-v4 任务上表现出稳定优势，五个随机种子均优于 LIF，平均最大评估回报提升约 48.14%；而在 InvertedDoublePendulum-v4 中二者基本持平，在 Ant-v4、HalfCheetah-v4 和 Hopper-v4 中暂未体现稳定优势。基于相关文献与现有实验，本文将 PLIF 的作用定位为任务相关的时间尺度自适应能力，而非对 LIF 的无条件替代。后续章节将从 τ 演化、固定 τ 消融以及 STBP 梯度传播角度进一步解释 PLIF 在脉冲强化学习中的适用边界。

关键词：脉冲神经网络；强化学习；PLIF 神经元；Proxy Target；连续控制；TD3

ABSTRACT

Spiking neural networks provide event-driven computation, temporal information processing, and potential energy-efficient deployment, but their discrete spike dynamics make continuous-control reinforcement learning difficult. This thesis studies whether PLIF neurons with learnable membrane time constants can improve the learning performance of spiking actors. Based on the Proxy Target and TD3 framework, fixed-decay LIF neurons are used as the main baseline, and the task-dependent effects of PLIF are analyzed on MuJoCo continuous-control benchmarks. Existing results show that PLIF achieves a stable advantage on Walker2d-v4, outperforming LIF under all five random seeds and improving the average maximum evaluation reward by about 48.14%. In contrast, PLIF is close to LIF on InvertedDoublePendulum-v4 and does not yet show stable gains on Ant-v4, HalfCheetah-v4, or Hopper-v4. Therefore, the thesis interprets PLIF as a task-adaptive temporal-scale modeling mechanism rather than an unconditional replacement for LIF. Subsequent analysis will further examine tau evolution, fixed-tau ablation, and STBP gradient propagation.

KEY WORDS: Spiking neural networks; Reinforcement learning; PLIF neuron; Proxy Target; Continuous control; TD3

目 录

摘 要.....	I
ABSTRACT.....	II
第一章 绪论.....	1
1.1 研究背景.....	1
1.2 问题提出.....	2
1.3 研究目标.....	2
1.4 主要贡献.....	3
第二章 相关理论与方法基础.....	3
2.1 强化学习与连续控制.....	3
2.2 脉冲神经网络.....	4
2.3 PLIF 神经元.....	5
2.4 代理梯度与 STBP.....	6
2.5 Proxy Target 框架.....	6
第三章 PLIF 脉冲 Actor 设计.....	7
3.1 整体网络结构.....	7
3.2 LIF 与 PLIF 的计算差异.....	7
3.3 PLIF tau 参数化.....	8
3.4 训练流程.....	9
参考文献.....	10

第一章 绪论

1.1 研究背景

强化学习研究智能体如何在与环境的连续交互中根据奖励信号改进决策策略。对于机器人控制、自动驾驶、无人系统和具身智能等问题，环境状态和动作空间往往是连续且高维的，策略网络需要在复杂动力学中学习稳定、平滑并具有泛化能力的动作输出。深度强化学习通过将深度神经网络作为函数逼近器显著提高了连续控制任务中的策略表示能力，但其训练和推理通常依赖密集矩阵运算，能耗和部署成本较高，限制了其在边缘设备和低功耗机器人平台中的应用。

脉冲神经网络被认为是更接近生物神经系统的第三代神经网络模型。与传统人工神经网络使用连续激活值不同，SNN 以离散脉冲事件传递信息，神经元内部还显式保留膜电位、电流和阈值等动态状态。这种事件驱动机制使 SNN 在神经形态芯片上具有低功耗、低延迟和稀疏计算的潜力。Fang 等提出的 PLIF 研究指出，SNN 不仅具有时序信息处理能力和生物可解释性，而且膜相关参数会直接影响单个神经元的动态响应与网络表达能力[1]。Tang 等的 PopSAN 工作进一步表明，将 population coding 引入脉冲 Actor 后，SNN 能够被用于连续控制任务，并可在神经形态硬件上获得明显能效优势[6]。

然而，将 SNN 直接用于强化学习中的连续控制并不容易。一方面，脉冲发放函数通常由阶跃函数描述，前向传播是离散的，标准反向传播难以直接求导另一方面，连续控制任务要求 Actor 输出连续动作，而 SNN 天然输出的是脉冲序列或脉冲率，二者之间存在表达形式上的差距。已有研究围绕这一问题提出了多种改进方向：Zhang 等通过多尺度动态编码增强脉冲 Actor 的时空表征能力[2]；Chen 等尝试构建全脉冲 Actor，并指出以脉冲率再接全连接层表示连续动作会引入额外浮点运算，从而削弱全脉冲部署优势[3]；Xu 等则从强化学习算法结构出发，提出 Proxy Target 框架以缓解 SNN 离散动态与连续控制目标网络更新机制之间的不匹配[4]。

在上述背景下，本文关注 PLIF 神经元在脉冲强化学习中的作用。PLIF 的核心思想是将膜时间常数或膜电位保留系数设为可学习参数，使神经元可以根据任务和训练过程调节自身时间尺度。对于连续控制任务，环境动力学通常包含不同长度的时序依赖，固定时间常数的 LIF 神经元可能难以同时适应短时响应和长时状态保持需求。因此，研究 PLIF 是否能在 Proxy Target 框架下提高 SNN Actor 的学习性能，既具有神经元动力学层面的理论意义，也具有低功耗连续控制部署方面的实际价值。

1.2 问题提出

传统 LIF 神经元使用固定的膜电位衰减系数。固定系数简化了模型和训练过程，但也意味着所有任务、所有网络层甚至所有训练阶段共享相同的时间尺度假设。当环境状态变化较快时，较大的膜电位保留可能造成历史信息干扰；当任务依赖更长时间的运动协调时，较小的保留系数又可能使关键时序信息过早衰减。连续控制任务之间存在显著动力学差异，例如倒立摆任务的回报较容易接近饱和，而 Walker2d-v4 涉及更复杂的双腿协调和接触动力学，对历史状态保持的需求可能更强。

PLIF 为这一问题提供了一个可学习的建模入口。Fang 等的研究表明，在监督学习任务中共同学习突触权重和膜时间常数可以提升 SNN 对初值的鲁棒性并加快学习[1]。但在强化学习场景中，策略学习的目标并非固定标签，而是由奖励、价值估计和环境交互共同决定；Actor 还要与 Critic、Replay Buffer、目标网络或 Proxy Target 形成耦合。因此，PLIF 在分类任务中的优势不能直接推断到连续控制强化学习中，需要结合具体算法框架重新验证。

此外，本文实验框架中同时存在两个名称相同但含义不同的 τ 。第一个 τ 来自 PLIF 神经元，表示膜电位衰减或保留相关的时间尺度参数；第二个 τ 来自 TD3 算法，表示目标网络软更新系数。Fujimoto 等提出的 TD3 通过双 Critic、延迟策略更新和目标策略平滑缓解 Actor-Critic 中的函数逼近误差与过估计问题[5]，其中软更新 τ 服务于目标网络稳定性。若不区分这两个 τ ，就容易把神经元动态的可学习时间尺度与强化学习算法的目标网络更新机制混为一谈。

因此，本文的问题可以概括为：在 Proxy Target + TD3 框架下，将 SNN Actor 中的 LIF 神经元替换为 PLIF 神经元，是否能够稳定提升连续控制性能；如果性能提升只在部分任务上出现，这种差异是否能够由任务时序依赖、 τ 学习趋势和梯度传播状态解释。围绕这一问题，论文不预设 PLIF 必然全面优于 LIF，而是把重点放在任务相关优势和适用边界的分析上。

1.3 研究目标

本文的总体目标是在已有 Proxy Target 代码与实验结果基础上，系统分析 PLIF 神经元在脉冲强化学习连续控制任务中的作用。具体而言，首先在相同 Actor-Critic 训练框架、相同环境和相同随机种子设置下，对比 LIF 与 PLIF 两类脉冲 Actor 的最大评估回报、学习曲线和 seed 级别胜负关系，判断 PLIF 优势是否稳定存在。

其次，本文拟分析 PLIF 中 τ 参数在不同任务和不同网络层中的演化趋势。若 PLIF 在某一任务中显著优于 LIF，则需要进一步观察隐藏层和输出层 τ 是

否偏离固定 LIF 值，以及这种偏离是否与更强历史信息保持或更快动态响应相一致。对于 PLIF 没有明显优势的任务，也需要分析 τ 是否学习不足、是否收敛到接近 LIF 的固定值，或是否可能增加优化难度。

再次，本文将通过固定 τ LIF 消融实验检验 PLIF 优势来源。如果某个固定 τ 设置能够接近 PLIF 性能，则说明 PLIF 主要起到了自动选择合适时间尺度的作用；如果 PLIF 仍优于所有固定 τ 设置，则说明按层学习、训练过程中的动态调节或与梯度传播的交互可能更加重要。最后，本文将结合 STBP 梯度打印结果，分析 PLIF 对脉冲 Actor 训练稳定性、梯度范数和 τ 参数更新的影响。

1.4 主要贡献

本文的第一项贡献是将 PLIF 神经元引入 Proxy Target + TD3 脉冲强化学习框架，并在多个 MuJoCo 连续控制环境上与固定 τ 的 LIF 神经元进行对齐比较。现有结果显示，PLIF 在 Walker2d-v4 上取得稳定且显著的优势，五个随机种子均优于 LIF，平均最大评估回报提升约 48.14%；在 InvertedDoublePendulum-v4 上两者基本持平，而在 Ant-v4、HalfCheetah-v4 和 Hopper-v4 中暂未表现出稳定优势。

第二项贡献是将 PLIF 的性能结论从“整体优劣比较”推进到“任务相关机制分析”。本文不把 PLIF 表述为 LIF 的全面替代，而是强调可学习 τ 为 SNN Actor 提供了任务自适应的时间尺度建模能力。这一表述既与 PLIF 文献中膜时间常数影响神经元动态的结论一致[1]，也与连续控制任务中不同环境动力学需求存在差异的实际情况相吻合。

第三项贡献是明确区分 PLIF 神经元 τ 与 TD3 软更新 τ ，并结合代码实现说明本文实验中的 PLIF τ 更接近膜电位衰减或保留系数。该澄清有助于避免概念混淆，也为后续固定 τ 消融、 τ 学习率设置和 STBP 梯度分析提供清晰的变量定义。

第二章 相关理论与方法基础

2.1 强化学习与连续控制

强化学习通常用马尔可夫决策过程描述。智能体在时刻 t 观察环境状态 s_t ，选择动作 a_t ，环境返回奖励 r_t 并转移到下一状态 s_{t+1} 。策略学习的目标是在长期交互中最大化折扣累计回报。与离散动作任务相比，连续控制任务要求策略直接输出连续动作向量，动作维度和状态维度通常较高，且系统动力学对动作扰动较敏感。因此，连续控制算法需要同时保证价值估计稳定性和策略更新平滑性。

Actor-Critic 框架将策略函数与价值函数分开建模。Actor 根据当前状态输出动作，Critic 估计状态-动作对的价值，并为 Actor 提供优化方向。确定性策略梯度方法适合连续动作空间，但在使用神经网络作为函数逼近器时，价值估计误差会被策略更新放大。Fujimoto 等指出，Actor-Critic 中同样存在过估计偏差和误差累积问题，并提出 TD3 算法进行改进[5]。

TD3 的核心机制包括三点。第一，使用两个 Critic 网络同时估计 Q 值，并在构造目标值时取二者较小值，以降低过估计风险。第二，延迟策略更新，即 Critic 更新多次后再更新 Actor，从而减少 Actor 追随不稳定价值估计的频率。第三，目标策略平滑，即在目标动作上加入裁剪噪声，使 Critic 学习到对相近动作更平滑的价值估计。本文实验以 TD3 为连续控制基础算法，因此后续所有 SNN Actor 的比较都建立在这一 Actor-Critic 框架之上。

2.2 脉冲神经网络

脉冲神经网络以离散脉冲作为主要信息载体。神经元在每个仿真时间步接收突触输入，更新膜电位，当膜电位超过阈值时发放脉冲并执行重置。与 ANN 的连续激活不同，SNN 的状态演化具有显式时间维度，能够在膜电位和脉冲序列中保存历史输入信息。正因为这一特点，SNN 被广泛用于低功耗、事件驱动和时序信息处理场景。

LIF 神经元是最常用的 SNN 基本模型之一。其膜电位在未发放脉冲时按固定比例保留历史状态，并叠加当前输入；当膜电位超过阈值后，神经元输出脉冲并重置或削弱膜电位。该模型结构简单、计算成本低，但固定膜电位衰减系数也限制了神经元对不同时间尺度的适应能力。Fang 等指出，膜相关参数决定单个神经元的动态特性，如果所有神经元共享同一固定时间常数，会削弱神经元异质性和网络表达能力[1]。

在强化学习连续控制中，SNN 还需要解决动作表达问题。Tang 等提出的 PopSAN 采用 population coding 将连续状态编码为脉冲群体活动，再通过脉冲 Actor 与深度 Critic 结合完成连续控制[6]。Zhang 等提出的 MDC-SAN 进一步将网络尺度的群体编码与神经元尺度的二阶动态编码结合，以增强空间-时间状态表征[2]。Chen 等则指出，许多方法使用脉冲率再经过全连接层表示连续动作，这会引入浮点矩阵运算；他们提出使用非脉冲神经元膜电位和层内连接构造更完整的全脉冲 Actor[3]。这些研究共同说明，SNN 用于连续控制的关键并不仅是替换网络结构，还包括编码、解码、神经元动态和训练算法的协同设计。

表 2-1 相关脉冲强化学习与 PLIF 研究对本文的启示

文献	核心思想	对本文的启示
Fang 等[1]	学习膜时间常数，增强 SNN 神经元异质性与学习能力。	为 PLIF τ 可学习提供直接理论依据。
Tang 等[6]	将 population coding 用于连续控制脉冲 Actor，并验证神经形态部署能效。	支撑本文采用群体编码/解码结构。
Zhang 等[2]	多尺度动态编码增强 SNN Actor 的时空表征。	说明连续控制任务需要更强时序动态建模。
Chen 等[3]	构建带层内连接的全脉冲 Actor，减少非脉冲浮点运算。	提示动作解码方式会影响 SNN 部署优势。
Xu 等[4]	以 Proxy Target 缓解 SNN 离散动态与连续控制软更新机制的矛盾。	构成本文实验框架。

2.3 PLIF 神经元

PLIF 神经元可以看作对 LIF 神经元的参数化扩展。LIF 中的膜电位保留或衰减系数通常由人工设定；PLIF 则将该参数纳入可学习变量，使其能够随误差反向传播更新。Fang 等将这种模型称为 Parametric Leaky Integrate-and-Fire 神经元，并指出可学习膜时间常数能够使网络对初始值不那么敏感，同时加快学习过程[1]。

需要注意的是，不同实现中 τ 的数学含义可能存在差异。在神经元动力学文献中， τ 常被称为膜时间常数，用于描述膜电位随时间衰减的速度；在本文代码中，PLIFNode 通过 $\text{sigmoid}(w)$ 得到一个位于 0 到 1 之间的系数，并在更新中写作膜电位的保留系数。由于当前 LIF 固定值为 0.75，PLIF 初始值也与该保留系数对齐。因此，本文后续讨论 τ 时，主要指代码实现中的膜电位保留/衰减系数，而不是连续时间微分方程中的物理时间常数。

从连续控制角度看，PLIF 的意义在于允许不同网络层学习不同的时间尺度。隐藏层 τ 较大时，膜电位对历史输入保留更强，有助于建模较长时间依赖； τ 较小时，神经元响应更偏向当前输入，有助于快速跟随状态变化。输出 population 层的 τ 还会影响动作脉冲活动的平滑程度。因此，PLIF 是否有效不只取决于是否可学习，还取决于任务动力学、层级功能和强化学习损失共同塑造出的 τ 演化路径。

2.4 代理梯度与 STBP

SNN 训练的主要困难来自脉冲发放函数不可导。阶跃函数在阈值处不连续，在其他位置梯度几乎为零，直接使用反向传播会导致参数难以更新。代理梯度方法用一个连续函数的导数近似阶跃函数的梯度，使网络在前向传播中保持脉冲离散性，在反向传播中获得可用梯度。Chen 等指出，代理梯度已经被用于训练多层 SNN，并使其在连续控制任务中能够达到接近对应深度网络的性能[3]。

STBP 将反向传播扩展到 SNN 的时间维度和层级维度。对于包含 T 个仿真时间步的脉冲网络，损失函数不仅通过网络层反传，也沿神经元状态的时间递推关系反传。因此，膜电位保留系数、脉冲发放稀疏性和重置机制都会影响梯度大小和传播路径。在本文实验中，STBP 梯度分析用于观察不同层、不同时间步和不同神经元类型下的梯度范数，从而判断 PLIF 是否改善了梯度过小、传播不稳定或脉冲活动过稀疏等问题。

对于 PLIF 而言，STBP 还承担了更新 τ 参数的功能。 τ 通过膜电位递推参与每个时间步的状态更新，其梯度来自 Actor 损失对膜电位动态的间接影响。如果 τ 参数梯度长期接近零，说明 PLIF 虽形式上可学习，但实际训练中可能难以调整时间尺度；如果 τ 梯度波动过大，则可能带来优化不稳定。因此， τ 梯度和普通权重梯度应作为后续机制分析的重要证据。

2.5 Proxy Target 框架

传统 TD3 使用目标 Actor 网络产生下一状态动作，并通过软更新使目标网络缓慢跟随当前 Actor。该机制在 ANN 中通常稳定有效，但 SNN Actor 的离散脉冲动态和不可导发放函数会使软更新后的目标网络表现出不连续或不平滑的行为。Xu 等指出，连续控制算法中的目标网络软更新机制与 SNN 的离散非可导动态存在冲突，可能造成训练不稳定和性能下降[4]。

Proxy Target 框架的核心思想是引入一个连续、可微的代理目标网络。训练时，当前 SNN Actor 输出动作，Proxy Target ANN 通过均方误差拟合该动作输出；Critic 构造目标值时使用 Proxy Target 产生下一状态动作。由于 Proxy Target 具有连续可微动态，其输出更适合 TD3 中的目标动作平滑和价值目标构造。与此同时，Proxy Target 只在训练阶段使用，部署时仍保留 SNN Actor，因此不会增加推理阶段的能耗开销[4]。

本文实验基于 Proxy Target + TD3 展开。代码中在 Proxy Target 更新阶段对 SNN Actor 输出使用 `torch.no_grad()`，使 Actor 动作只作为监督标签，不让 proxy loss 反向传播回 SNN Actor。这样既符合 Proxy Target 的优化目标，也避免每次 proxy iteration 都额外触发一次 SNN Actor 的 STBP 反向计算。随后算法按 TD3 流程更新 Critic，并以延迟策略更新方式优化 SNN Actor。对于 PLIF Actor， τ

参数与普通 Actor 权重采用不同学习率，以降低时间尺度参数过快变化造成的不稳定风险。

第三章 PLIF 脉冲 Actor 设计

3.1 整体网络结构

本文的脉冲 Actor 采用“Population Spike Encoder—Spike MLP—Population Decoder”的整体结构。该结构继承了 PopSAN 类方法的基本思想：先用群体神经元把连续状态编码为脉冲序列，再由脉冲多层感知机在若干仿真时间步内完成时序计算，最后把输出 population 活动解码为连续动作。这样的设计既保留了 SNN 事件驱动和时序计算的特点，又能够满足连续控制任务对动作向量的输出要求。

输入端的 Population Spike Encoder 将每个状态维度扩展为若干个编码神经元。每个编码神经元对应不同的感受野均值，输入状态经过高斯形状的 population 活动函数后，在多个仿真时间步中生成规则脉冲序列。与单神经元编码相比，population coding 提高了连续状态的表示分辨率，也为后续 SNN 层提供更丰富的稀疏输入。Tang 等的研究表明，population-coded spiking actor 能够与深度 Critic 结合用于连续控制任务[6]，这为本文结构选择提供了直接参考。

中间的 Spike MLP 由若干线性突触层和脉冲神经元层组成。对于 LIF、CLIF 和 PLIF 三种设置，线性层结构保持一致，差异主要体现在神经元状态更新方式上。隐藏层负责从输入脉冲序列中提取时序特征，输出 population 层则累计各时间步的脉冲活动，并在仿真结束后取平均作为动作解码输入。

输出端的 Population Decoder 按照动作维度分组，将每个动作维度对应的一组 population 活动映射为一个连续动作分量，并通过 tanh 函数和动作范围系数限制输出。相比直接使用单个脉冲神经元表示动作，population decoder 能够利用一组神经元的活动分布表达连续值，从而缓解脉冲离散性与连续动作空间之间的矛盾。

3.2 LIF 与 PLIF 的计算差异

在当前实现中，LIF 和 PLIF 共享相同的突触输入计算方式，二者的差异主要体现在膜电位保留系数是否可学习。为避免与 TD3 目标网络软更新系数 τ_{TD3} 混淆，本文在本节中用 α 表示神经元膜电位保留系数。设 t 为 SNN 仿真时间步， k 为网络层， I_t^k 为第 k 层在 t 时刻的突触输入， V_t^k 为膜电位， S_t^k 为脉冲输出， Θ 为阶跃发放函数， σ 为 sigmoid 函数，则第 k 层神经元状态递推可写为：

$$I_t^k = W^k S_{t-1}^{k-1} + b^k \quad (3-1)$$

$$V_t^k = \alpha^k V_{(t-1)}^k (1 - S_{(t-1)}^k) + I_t^k \quad (3-2)$$

$$S_t^k = \Theta(V_t^k - V_{th}) \quad (3-3)$$

其中 $(1 - S_{(t-1)}^k)$ 表示上一时间步发放脉冲后对膜电位进行重置或抑制。该形式使发放过脉冲的神经元在下一步不会简单累积过高历史膜电位，从而维持脉冲发放的离散事件特性。

在上述统一记号下，LIF 与 PLIF 的区别可以进一步写成膜电位保留系数 α^k 的不同取值。LIF 使用固定保留系数 $\alpha_{LIF}=0.75$ ；PLIF 则将该系数参数化为 $\alpha_{PLIF}^k=\sigma(w^k)$ ，其中 w^k 为第 k 层 PLIF 神经元模块中的可学习参数。

$$\alpha^k = \alpha_{LIF} = 0.75 \quad (\text{LIF}) \quad (3-4)$$

$$\alpha^k = \alpha_{PLIF}^k = \sigma(w^k), \quad w^k \text{ learnable} \quad (\text{PLIF}) \quad (3-5)$$

因此，PLIF 并未改变 Actor 的输入输出接口，也未改变突触层数量和隐藏单元规模，而是在神经元状态递推中引入可学习时间尺度。若 α_{PLIF}^k 学习到较大值，膜电位保留更强，历史输入对当前状态影响更久；若学习到较小值，神经元更快遗忘历史状态，对当前输入更加敏感。

这种差异看似只改变一个系数，但在多时间步 STBP 中会影响整个梯度传播路径。由于膜电位递推跨越多个仿真时间步， α_{PLIF} 不仅影响前向脉冲活动，也影响损失函数对早期输入和早期膜电位状态的梯度。代码日志中输出的 τ 对应本节的 α_{PLIF} ，而不是 TD3 中的 τ_{TD3} 。PLIF 的潜在优势正来自这种前向动态与反向梯度路径的共同调整。

表 3-1 LIF 与 PLIF 神经元状态更新差异

神经元类型	膜电位保留系数	参数更新	本文关注点
LIF	$\alpha_{LIF}=0.75$	仅更新突触权重	作为固定时间尺度基线。
PLIF	$\alpha_{PLIF}^k=\sigma(w^k)$ ，初始对齐 0.75	同时更新突触权重 与 w^k	分析任务相关时间尺度自适应。
CLIF	固定电压衰减并引入电流衰减	更新突触权重	作为补充对照，区分电流动态影响。

3.3 PLIF τ 参数化

当前代码中的 PLIFNode 使用一个可学习标量 w 表示每个 PLIF 神经元模块的时间尺度参数，并通过 sigmoid 函数将其映射到 0 到 1 之间。初始化时， w 根据目标初始 τ 反推得到，使 PLIF 的初始膜电位保留系数与 LIF 固定值 0.75 对齐。这样可以保证 LIF 与 PLIF 比较时，初始动态尽可能一致，避免把初值差异误判为可学习机制带来的性能变化。

在 Spike MLP 中，每个隐藏层和输出 population 层各配置一个 PLIFNode。因此，在两层隐藏层设置下，PLIF Actor 通常包含 hidden0、hidden1 和 output 三个 τ 轨迹。按层设置 τ 比全网络共享一个 τ 更灵活，因为不同层承担的功能并不相同：浅层更接近编码输入，可能需要快速响应状态变化；深层负责组合时序特征，可能需要更长历史保持；输出层直接影响动作脉冲活动，其 τ 变化会影响动作平滑性。

τ 参数与普通权重使用不同学习率。代码中 PLIF 参数单独分组，Proxy Target 版本默认将 PLIF 学习率设置为 proxy_lr 的一定比例。这样做的原因是 τ 直接控制神经元状态递推，变化过快可能导致脉冲发放率、膜电位分布和梯度范数同时波动，从而破坏强化学习训练稳定性。后续实验如果观察到 τ 变化过慢或过快，需要结合 PLIF 学习率进一步分析。

本文在解释 τ 曲线时，需要始终围绕“膜电位保留系数”这一代码语义展开。若某任务中 hidden τ 明显升高，可以解释为模型倾向于保留更长历史信息；若 output τ 降低，则可能表示输出动作更依赖当前时刻特征或需要更快更新。该解释不能简单等同于 TD3 目标网络软更新 τ ，也不能直接套用连续时间神经元模型中的物理时间常数含义。

3.4 训练流程

本文训练流程以 Proxy Target + TD3 为主线。Proxy Actor 仅在训练阶段作为连续、可微的目标策略近似器使用；部署阶段仍保留 SNN Actor。为清晰说明各网络之间的更新关系，算法 3-1 给出本文采用的训练流程，其中 τ_{TD3} 表示目标 Critic 软更新系数，PLIF 神经元中的膜电位保留系数仍记为 α_{PLIF} 。

算法 3-1 Proxy Target + TD3 下的 PLIF 脉冲 Actor 训练流程

Input: 环境 E , Replay Buffer D , SNN Actor π_{ϕ}^{SNN} , Proxy Actor $\pi_{\phi'}^{\text{P}}$,
 双 Critic $Q_{\theta 1}, Q_{\theta 2}$, 目标 Critic $Q_{\theta 1'}, Q_{\theta 2'}$,
 折扣因子 γ , 目标网络软更新系数 τ_{TD3} , proxy 更新次数 K , batch size N , 延迟策略更新频率 d

Output: 训练后的 SNN Actor π_{ϕ}^{SNN}

Initialize $\pi_{\phi}^{\text{SNN}}, \pi_{\phi'}^{\text{P}}, Q_{\theta 1}, Q_{\theta 2}, Q_{\theta 1'}, Q_{\theta 2'}$ and D

for each environment step do

 根据当前 SNN Actor 选择动作 a_t ，并与环境交互得到 (s_t, a_t, r_t, s_{t+1})

 将转移样本存入 D

 for $k = 1$ to K do

 从 D 中采样小批量状态 s_i

 在 no_grad 模式下计算动作标签 $a_i^{\text{SNN}} = \pi_{\phi}^{\text{SNN}}(s_i)$

 更新 Proxy Actor，使其最小化 $L_{\text{proxy}} = 1/N \sum_i \|\pi_{\phi'}^{\text{P}}(s_i) - a_i^{\text{SNN}}\|_2^2$

 end for

 从 D 中采样小批量转移 $(s_i, a_i, r_i, s_{i'})$

 使用 Proxy Actor 生成目标动作，并加入 TD3 目标策略平滑噪声

$y_i = r_i + \gamma \min_j Q_{\theta j'}(s_{i'}, a_i')$

 更新双 Critic，使其最小化 TD 误差

```

if 当前迭代满足延迟策略更新条件 then
    更新 SNN Actor, 使  $L_{actor} = -1/N \sum_i Q_{\theta 1}(s_i, \pi_{\phi}^{SNN}(s_i))$  最小
    若 Actor 为 PLIF, 同步通过 STBP 更新突触权重和  $w^k$ 
    软更新目标 Critic:  $\theta_j' \leftarrow \tau_{TD3} \theta_j + (1 - \tau_{TD3}) \theta_j'$ 
end if
end for

```

算法 3-1 中, Proxy Actor 的监督标签由当前 SNN Actor 在无梯度模式下产生, 因此 proxy loss 只更新 Proxy Actor 参数, 不会反向传播到 SNN Actor。Critic 更新时使用 Proxy Actor 产生下一状态动作, 并通过双 Q 较小值构造 TD 目标; Actor 则按照 TD3 的延迟策略更新机制, 由 Critic 给出的 Q 值优化当前 SNN 策略。

当 Actor 为 PLIF 脉冲网络时, Actor 反向传播会同时更新普通突触权重和 w^k 参数。由于 w^k 通过 $\alpha_{PLIF}^k = \sigma(w^k)$ 参与每个仿真时间步的膜电位递推, 其梯度需要通过 STBP 在时间维度上累计。因此, PLIF 训练不仅是参数数量增加, 也改变了 Actor 内部时序动态的可调方式。本文后续实验分析将围绕性能证据、 α_{PLIF} 轨迹和梯度证据展开, 以判断 PLIF 在 Walker2d-v4 上的优势是否来自更合适的时间尺度建模, 以及为何这种优势没有在所有任务上同时出现。

参考文献

- [1] Fang W, Yu Z, Chen Y, et al. Incorporating learnable membrane time constant to enhance learning of spiking neural networks[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 2661-2671.
- [2] Zhang D, Zhang T, Jia S, et al. Multi-Sacle Dynamic Coding Improved Spiking Actor Network for Reinforcement Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022, 36(1): 59-67.
- [3] Chen D, Peng P, Huang T, et al. Fully spiking actor network with intralayer connections for reinforcement learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 36(2): 2881-2893.
- [4] Xu Z, Bu T, Hao Z, et al. Proxy Target: Bridging the Gap Between Discrete Spiking Neural Networks and Continuous Control[J]. arXiv preprint arXiv:2505.24161, 2025.

[5] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]//International Conference on Machine Learning. PMLR, 2018: 1587-1596.

[6] Tang G, Kumar N, Yoo R, et al. Deep Reinforcement Learning with Population-Coded Spiking Neural Network for Continuous Control[J]. arXiv preprint arXiv:2010.09635, 2020.